

Proyecto asignatura Estadística (MAT3) GIN2 Grupos 1 y 3:

PARTE 1 Curso 2020-2021

Marc Cañellas, Eduardo Bonnin, Jaume Adrover, Joan Balaguer

23/4/2021

Contenidos

0.1 Solución apartados 1 y 2	2
0.2 Solución apartado 3	3
0.3 Solución apartado 4	4
0.4 Solución apartado 5	5
0.5 Solución apartado 6	14
0.6 Solución apartado 7	15
0.7 Solución apartado 8	16
0.8 Solución apartado 9	17
0.9 Solución apartado 10	19
0.10 Solución apartado 11	20
0.11 Solución apartado 12	20

1. Cargad en un `dataframe` los datos del fichero `listings.csv` (descomprimido a partir de `listings.csv.gz`). Esta tabla de datos contiene datos sobre muchas variables:

- `neighbourhood` `property_type`
- `accommodates`
- `beds`
- `bedrooms`
- `bathrooms`
- `price`
- `security_deposit`
- `minimum_nights`
- `review_scores_rating`
- `number_of_reviews`
- `host_response_time`
- `requires_license`
- `review_scores_cleanliness`
- `cleaning_fee`
- etc.

Construid un nuevo `data frame` que contenga solo la información relativa a como mínimo 3 variables no numéricas y 7 variables numéricas. Hay que **escoger forma obligatoria las variables** `neighbourhood` y `price`. Las variables relativas a precioso (por ejemplo, `price` y `security_deposit`) se consideran numéricas, pero primero deben convertirse a valores numéricos eliminando los símbolos \$ o €; por ejemplo utilizando la función `gsub(pattern="[\\$]",replacement="",x="$10,000");` haced (`help(gsub)`)

2. Renombrar las columnas del `dataframe` con nombres en castellano o catalán.

0.1 Solución apartados 1 y 2

A nuestro grupo (Los Discretos), le ha tocado la ciudad de Western Australia. Vamos a cargar los datos del documento de datos listing.csv en un data frame que llamaremos AUS. En nuestro caso, este data frame estará conformado por las variables cuantitativas price,latitude,longitude,bedrooms,beds,acomodates y minimum_nights, y las variables cualitativas host_id,host_name,neighbourhood y host_location del archivo de donde hemos leído los datos. En el apartado 2, hemos modificado estos nombres y los hemos sustituido por sus respectivos nombres en español.

```
#Cargamos los Datos
df=read.csv("listings.csv", header=TRUE)

## Warning in scan(file = file, what = what, sep = sep, quote = quote, dec = dec, :
## EOF within quoted string

#Cuantitativas
precio=as.numeric(gsub(pattern = "[\\$]|[,]",replacement = "", df$price))
latitud=df$latitude
longitud=df$longitude
dormitorios=df$bedrooms
camas=df$beds
acomodaciones=df$accommodates
noches_minimas=df$minimum_nights

#Cualitativas
id_anfitrión=df$host_id
nombre_anfitrión=df$host_name
vecindario=df$neighbourhood
localización=df$host_location

#Creamos nuestro Data Frame llamado AUS
AUS = data.frame(precio,
                 latitud,
                 longitud,
                 dormitorios,
                 camas,
                 acomodaciones,
                 noches_minimas,
                 id_anfitrión,
                 nombre_anfitrión,
                 vecindario,
                 localización
                 )

#Vemos la estructura general de nuestro data frame
str(AUS)

## 'data.frame':   7069 obs. of  11 variables:
## $ precio      : num  95 64 94 220 65 70 74 156 100 70 ...
## $ latitud     : num  -32 -32.1 -29.3 -34.4 -32.1 ...
## $ longitud    : num  116 116 115 116 116 ...
## $ dormitorios : int   2 1 1 5 1 1 1 2 1 1 ...
## $ camas       : int   3 1 1 6 1 1 1 2 1 1 ...
## $ acomodaciones : int   5 1 2 8 1 2 2 4 2 2 ...
## $ noches_minimas : int   2 1 1 2 1 2 2 5 1 2 ...
## $ id_anfitrión : int  2313 162227 186576 277321 284743 319052 348191 431695 275749 474393 ...
```

```
## $ nombre_anfitrión: chr "Helen" "Theja" "Denise" "Karen" ...
## $ vecindario : chr "Como, Western Australia, Australia" "" "Dongara, Western Australia, Austr
## $ localización : chr "Perth, Western Australia, Australia" "Perth, Western Australia, Australia"
```

3. Para las variables numéricas, calcular los siguientes estadísticos y mostrar en una tabla los siguiente valores: cantidad de valores no válidos, mínimo, máximo, media, varianza, cuartiles y mediana.

0.2 Solución apartado 3

```
#Hemos creado una funcion que implementa todos los calculos del apartado 3
apartado3=function(x){
  c(
    #Media
    media=mean(x,na.rm = TRUE),
    #Mediana
    mediana=median(x,na.rm = TRUE),
    #Maximo
    max=max(x,na.rm = TRUE),
    #Mínimo
    min=min(x,na.rm = TRUE),
    #Cuartil0.25
    cuantil1=quantile(x,0.25,na.rm = TRUE),
    #Cuartil0.5
    cuantil2=quantile(x,0.5,na.rm = TRUE),
    #Cuartil0.75
    cuantil3=quantile(x,0.75,na.rm = TRUE),
    #Varianza
    varianza=var(x,na.rm = TRUE)*(length(x)-1)/length(x),
    #El numero de NA's
    numeroNA=ifelse(is.na(table(is.na(x)) [2]),0,table(is.na(x)) [2]))
  }

#Aplicamos la función apartado3 con cada una de las variables cuantitativas elegidas
salida= apply(AUS[,1:7], MARGIN = 2, FUN = apartado3)
rownames(salida)=c("Media","Mediana","Maximo","Mínimo","Cuartil0.25","Cuartil0.5","Cuartil0.75","Varianza")
knitr::kable(salida)
```

	precio	latitud	longitud	dormitorios	camas	acomodaciones	noches_minimas
Media	206.9281	-32.139216	115.983934	2.210996	3.013318	4.698783	3.394878
Mediana	150.0000	-32.051105	115.767255	2.000000	2.000000	4.000000	2.000000
Maximo	14575.0000	-15.719970	128.778580	50.000000	49.000000	16.000000	365.000000
Mínimo	15.0000	-35.090420	113.528300	1.000000	0.000000	1.000000	1.000000
Cuartil0.25	95.0000	-33.638060	115.332077	1.000000	1.000000	2.000000	1.000000
Cuartil0.5	150.0000	-32.051105	115.767255	2.000000	2.000000	4.000000	2.000000
Cuartil0.75	244.0000	-31.924660	115.894752	3.000000	4.000000	6.000000	3.000000
Varianza	139933.1312	6.918094	2.089626	2.110338	5.106653	8.080887	159.042575
Numero de NA's	1.0000	1.000000	1.000000	230.000000	11.000000	1.000000	1.000000

4. Para las variables no numéricas, generad las tablas de frecuencias absolutas de cada uno de sus valores.

0.3 Solución apartado 4

#Frecuencias absolutas

```
tabla1=sort(table(AUS$nombre_anfitrión, exclude = ""),decreasing = TRUE, na.rm=TRUE)[1:10]
knitr::kable(tabla1, col.names = c("Nombres","Freq"))
```

Nombres	Freq
Exclusiveescapes	72
Peter	65
Davinia	58
Michael	55
Chris	53
Lisa	52
Paul	49
Phoebe	49
Helen	46
Mary	46

```
tabla2=sort(table(AUS$vecindario, exclude = ""),decreasing = TRUE,na.rm=TRUE)[1:10]
knitr::kable(tabla2, col.names = c("Vecindarios","Freq"))
```

Vecindarios	Freq
Margaret River, Western Australia, Australia	235
Fremantle, Western Australia, Australia	196
Perth, Western Australia, Australia	171
Dunsborough, Western Australia, Australia	164
Scarborough, Western Australia, Australia	113
Yallingup, Western Australia, Australia	92
Cottesloe, Western Australia, Australia	67
Subiaco, Western Australia, Australia	66
Cable Beach, Western Australia, Australia	61
West Perth, Western Australia, Australia	60

```
tabla3=sort(table(AUS$localización, exclude = ""),decreasing = TRUE,na.rm=TRUE)[1:10]
knitr::kable(tabla3, col.names = c("Localizaciones","Freq"))
```

Localizaciones	Freq
Perth, Western Australia, Australia	1489
AU	675
Western Australia, Australia	594
Margaret River, Western Australia, Australia	340
Fremantle, Western Australia, Australia	240
Dunsborough, Western Australia, Australia	184
Busselton, Western Australia, Australia	154
Yallingup, Western Australia, Australia	139
Australia	133
Albany, Western Australia, Australia	97

```
tabla4=sort(table(AUS$id_anfitrion, exclude = ""),decreasing = TRUE,na.rm=TRUE)[1:10]
knitr::kable(tabla4, col.names = c("Identificadores","Freq"))
```

Identificadores	Freq
511967	72
15360130	58
73686458	41
106486177	41
170107339	34
269664436	31
33703497	27
215985827	26
22742955	25
34477031	25


5. Dibujar diagramas de cajas(**boxplots**) e histogramas de todas las variables numéricas, mostrando un mínimo de 2 **boxplot** por fila. Ajustad la altura de los gráficos para que no queden demasiado pequeños.

0.4 Solución apartado 5


```
#Boxplots de las variables cuantitativas
par(mfrow=c(2,2))

boxplot(AUS$noches_minimas,main="Noches mínimas")
boxplot(AUS$precio,main="Precio")
boxplot(AUS$latitud,main="Latitud")
boxplot(AUS$longitud,main="Longitud")
```


Noches mínimas




Precio



Latitud




Longitud




```
boxplot(AUS$camas,main="Camas")
boxplot(AUS$dormitorios,main="Dormitorios")
boxplot(AUS$acomodaciones,main="Acomodaciones")

par(mfrow=c(1,1))
```


Camas



Dormitorios




Acomodaciones



#Histogramas de las variables cuantitativas


```
hist(AUS$id_anfitrión, main="Id_Anfitrión", xlab="Id de anfitrión", ylab="", col="red")
```

Id_Anfitrión




```
hist(AUS$latitud,main="Histograma de latitudes",xlab="Latitud",ylab="",col="yellow")
```


Histograma de latitudes




```
hist(AUS$longitud,main="Histograma de longitudes",xlab="Longitud",ylab="",col="green")
```

Histograma de longitudes




```
barplot(table(AUS$dormitorios),col = "blue",main = "Gráfico de dormitorios",xlab = "Dormitorios",ylab="
```

Gráfico de dormitorios




```
hist(AUS$camas,main="Gráfico con el número de camas",xlab="Camas",col="cyan",ylab="")
```

Gráfico con el número de camas



```
hist(AUS$acomodaciones,main="Nombre de acomodaciones",xlab="Acomodaciones",col="brown",ylab="")
```


Nombre de acomodaciones



#Hacemos un barplot y no un histograma para la variable precio, ya que los datos se ven mucho más claros.

```
barplot(table(AUS$precio),main="Precios de las viviendas",xlab="Precios",ylim=c(0,200))
```

Precios de las viviendas



6. Dibuja un diagrama de tarta para una de las variables no numéricas agrupando como “Otros” los valores que representen un porcentaje inferior al 1% del total.

0.5 Solución apartado 6


```
#Pasamos la variable a un dato de tipo caracter
var =as.character(AUS$localización)

#Insertamos en una variable la tabla de frecuencias relativas de localización
tbl=prop.table(table(var))

#Identificamos, que valores de la variable localización suponen menos del 5%
 #(hemos puesto los que suponen menos del 5% y no los que suponen el 1% porque
 #el diagrama queda mucho mas claro)
otros= names(tbl)[which(tbl<=0.05)]

#Cambiamos los valores que suponen menos del 1% del total por el nombre "otros"
var[var %in% otros]="otros"

#Diagrama de pastel de la variable localización
pie(prop.table(table(var)))
```



7. Calcular el valor medio de alguna de las variables numéricas según el barrio, de menor a mayor y sin tener en cuenta nombres de Barrio incorrectas ("" o "N/A").

0.6 Solución apartado 7

```
#Creamos nuestro dataframe modificado a partir de 2 variables
d = data.frame(Barrio=AUS$vecindario,precio=AUS$precio )

#Creamos un segundo dataframe donde relacionamos las variables Barrio y precio, haciendo la mediana
Stats <- d %>% group_by(Barrio) %>% summarize(Media = mean(precio, na.rm = TRUE))

#Ordenamos las 5 primeras medianas
mediabaja=head(Stats %>% arrange(Media),5)
mediaalta=head(Stats %>% arrange(desc(Media)),5)

#Visualización
mediabaja
```

```
## # A tibble: 5 x 2
##   Barrio                               Media
##   <chr>                               <dbl>
## 1 Moora, Western Australia, Australia    15
## 2 Nilgen, Western Australia, Australia    25
## 3 Riverton, Western Australia, Australia    29
## 4 Lockridge, Western Australia, Australia    33
## 5 Parmelia, Western Australia, Australia    33.5
```

```
mediaalta
```


```
## # A tibble: 5 x 2
##   Barrio                               Media
##   <chr>                               <dbl>
## 1 Bovell, Western Australia, Australia 1050.
## 2 Bramley, Western Australia, Australia  973
## 3 Wonnerup, Western Australia, Australia 688.
## 4 Camballin, Western Australia, Australia 601
## 5 Perth Hills, Western Australia, Australia 595
```

8. Dibuja un **boxplot** de la variable precio, para los 5 barrios más caros (precio medio más alto) y los 5 barrios más baratos (precio medio más bajo), en un mismo diagrama. Los **boxplots** deben indicar también el valor medio de los datos.

0.7 Solución apartado 8


```
#Eliminamos el String "Western Australia,Australia" mediante un substring
barrio2=substr(mediabaja$Barrio, 1, 8)
Barrios=(gsub(pattern = "[\\W]|[,]",replacement = "", barrio2))

#Boxplot de la media de los 5 más barrios más baratos
p <- ggplot(mediabaja, aes(x=Barrios, y=Media)) +
  geom_boxplot()
p
```




```
#Asignamos a Barrios los nombres de los barrios más caros
barrio2=substr(mediaalta$Barrio, 1, 8)
Barrios=barrio2

#Boxplot de la media de los 5 barrios más caros
q <- ggplot(mediaalta, aes(x=Barrios, y=Media)) +
  geom_boxplot()
q
```



9. Para 4 de las variables numéricas dibujar los diagramas de dispersión dos a dos, con colores diferentes para cada barrio (“neighbourhood”).

0.8 Solución apartado 9

```
# numero zonas
n=length(unique(AUS$vecindario))
n

## [1] 637
par(mfrow=c(3,2))

#Diagrama de dispersión Precio-Noches
plot(AUS$precio,AUS$noches_minimas, main = "Dispersión Precio-Noches ",
     pch = 21, bg = rainbow(n)[factor(AUS$vecindario)], xlab="Precio", ylab="Noches")

#Diagrama de dispersión Precio-Latitud
```

```

plot(AUS$precio,AUS$latitud, main = "Dispersión Precio-Latitud ",
     pch = 21, bg = rainbow(n)[factor(AUS$vecindario)],xlab="Precio",ylab="Latitud")


#Diagrama de dispersión Precio-Longitud
plot(AUS$precio,AUS$longitud, main = "Dispersión Precio-Longitud ",
     pch = 21, bg = rainbow(n)[factor(AUS$vecindario)],xlab="Precio",ylab="Longitud")

#Diagrama de dispersión Noches-Latitud
plot(AUS$noches_minimas,AUS$latitud, main = "Dispersión Noches-Latitud ",
     pch = 21, bg = rainbow(n)[factor(AUS$vecindario)],xlab="Noches",ylab="Latitud")

#Diagrama de dispersión Noches-Longitud
plot(AUS$noches_minimas,AUS$longitud, main = "Dispersión Noches-Longitud ",
     pch = 21, bg = rainbow(n)[factor(AUS$vecindario)],xlab="Noches",ylab="Longitud")

#Diagrama de dispersión Latitud-Longitud
plot(AUS$latitud,AUS$longitud, main = "Dispersión Latitud-Longitud ",
     pch = 21, bg = rainbow(n)[factor(AUS$vecindario)],xlab="Latitud",ylab="Longitud")

```



```

par(mfrow=c(1,1))

```

10. Por las mismas variables elegidas en el apartado anterior calcular los coeficientes de correlación dos a dos de las variables, sin tener en cuenta los valores NA.

0.9 Solución apartado 10

```
#Calculamos las correlaciones dos a dos para las variables anteriores
cor1=na.omit(cor(AUS$noches_minimas,AUS$precio))
cor1
```

```
## numeric(0)
## attr(,"na.action")
## [1] 1
## attr(,"class")
## [1] "omit"
```

```
cor2=na.omit(cor(AUS$noches_minimas,AUS$longitud))
cor2
```

```
## numeric(0)
## attr(,"na.action")
## [1] 1
## attr(,"class")
## [1] "omit"
```

```
cor3=na.omit(cor(AUS$noches_minimas,AUS$latitud))
cor3
```

```
## numeric(0)
## attr(,"na.action")
## [1] 1
## attr(,"class")
## [1] "omit"
```

```
cor4=na.omit(cor(AUS$precio,AUS$latitud))
cor4
```

```
## numeric(0)
## attr(,"na.action")
## [1] 1
## attr(,"class")
## [1] "omit"
```

```
cor5=na.omit(cor(AUS$precio,AUS$longitud))
cor5
```

```
## numeric(0)
## attr(,"na.action")
## [1] 1
## attr(,"class")
## [1] "omit"
```

```
cor6=na.omit(cor(AUS$latitud,AUS$longitud))
cor6
```

```
## numeric(0)
## attr(,"na.action")
## [1] 1
## attr(,"class")
## [1] "omit"
```

11. Selecciona dos variables numéricas, y para cada una de ellas organiza sus valores en un máximo de 5 intervalos con la función `cut`.

0.10 Solución apartado 11

```
#Hacemos subdivisiones de las variables precio y dormitorios
corte1=cut(AUS$precio, breaks=c(0,100,200,300,600,Inf), include.lowest = TRUE)
corte10=na.omit(corte1)
corte10[1:10]
```

```
## [1] [0,100] [0,100] [0,100] (200,300] [0,100] [0,100] [0,100]
## [8] (100,200] [0,100] [0,100]
## Levels: [0,100] (100,200] (200,300] (300,600] (600,Inf]
```

```
corte2= cut(AUS$dormitorios, breaks=c(0,2,4,6,8,Inf), include.lowest = TRUE)
corte20=na.omit(corte2)
corte20[1:10]
```

```
## [1] [0,2] [0,2] [0,2] (4,6] [0,2] [0,2] [0,2] [0,2] [0,2] [0,2]
## Levels: [0,2] (2,4] (4,6] (6,8] (8,Inf]
```

12. A partir de los datos en intervalos obtenidos en el apartado anterior construid una tabla de contingencia de las dos variables y dibuja el diagrama de mosaico asociado a la mesa.

0.11 Solución apartado 12

```
#Tabla de contingencia de las variables que hemos creado en el apartado anterior
table(corte10)
```

```
## corte10
## [0,100] (100,200] (200,300] (300,600] (600,Inf]
##      2081      2676      1205      905      201
```

```
table(corte20)
```

```
## corte20
## [0,2] (2,4] (4,6] (6,8] (8,Inf]
##  4266  2312   245    10     6
```

```
#Diagrama de mosaico de las dos variables que hemos creado en el apartado anterior
plot(corte2,corte1, col="purple",ylab="Dormitorios",xlab="Precio")
```

