

Practica 6

Jaume Adrover Fernández
43235882E

Puntuación máxima: 1 punto

ENUNCIADO

El objetivo de esta práctica es la comprensión del concepto de caracterización de la carga. Para ello, se hará uso de la herramienta Weka. De la monitorización de un sistema de almacenamiento, se ha obtenido se proporciona un fichero de datos llamado data.txt. En el fichero se almacenan tres columnas con la siguiente información:

- El tamaño del fichero accedido (en MB). Los valores que correspondan con “-1” quieren decir que el acceso al fichero ha fallado.
- La hora a la que se hizo el acceso. El valor 22 representan las 22h, el valor 01 representan las 1h (a.m.), etc.
- El ancho de banda consumido (en MB/s). Los valores de esta columna están entre 453 y 1355, por lo tanto, los valores de esta columna deberán ser tratados. Es decir, el valor crudo de “1258.84,”, corresponde con “1258,84”. Con los datos proporcionados se pide caracterizar la carga haciendo uso del algoritmo de Kmeans y responder a las siguientes preguntas:
- Aplicando el algoritmo con 100 iteraciones y agrupando los datos en 3 clases, ¿qué resultados se obtienen? Muéstralo gráficamente.
- Con el mismo número de iteraciones y agrupando los datos en 5 clases, ¿qué resultados se obtienen? ¿Cómo difieren de los anteriormente obtenidos?
- ¿Hay alguna característica especial en la carga proporcionada? Explícala con detalle.


SOLUCIÓN

0. Introducción

Primero de todo, vamos a definir las condiciones en las que vamos a realizar la caracterización de la carga. Ya que la hora no determina el tamaño del fichero, además de que solo tenemos las horas 22,23,1,2,3,4,5, podemos eliminar la columna de **hour**, ya que no contribuye a nuestro análisis. El algoritmo a utilizar para el clustering es el SimpleKMeans, con un número de iteraciones a 100 y 3 o 5 clusters, dependiendo del apartado.

1. **Aplicando el algoritmo con 100 iteraciones y agrupando los datos en 3 clases, ¿qué resultados se obtienen? Muéstralo gráficamente.**

Si aplicamos el algoritmo con 100 iteraciones y agrupamos los datos en 3 clases, obtenemos los siguientes resultados:



Como podemos observar, este gráfico no clasifica según nuestros gustos los datos ya que los clusters solo se agrupan por velocidad MB/s. Es decir, podemos apreciar que la información se agrupa por filas y los puntos están muy separados, pudiendo formar más grupos. Esta clasificación engloba a los ficheros grandes, medianos y pequeños en un mismo cluster, solo observando el ritmo de transferencia. Debemos realizar nosotros una clasificación cualitativa y separar los grupos también por tamaño de fichero.

Veámoslo:



A continuación, podemos apreciar 9 clusters diferentes, cuando inicialmente solo había 3. La primera columna corresponde a los ficheros pequeños, ya que es el extremo más izquierdo del eje X. De arriba a abajo en el eje Y, pasamos por velocidad rápida, velocidad media y velocidad lenta. Por ejemplo, cojamos las columnas por separado:

-Primera columna(ficheros pequeños): el primer grupo superior corresponde a los ficheros pequeños con mayor rapidez, el de abajo velocidad media y como último los más lentos.

-Segunda columna(ficheros medianos): el primer grupo superior corresponde a los ficheros medianos con mayor rapidez, el de abajo velocidad media y como último los más lentos.


-Tercera columna(ficheros grandes): el primer grupo superior corresponde a los ficheros grandes con mayor rapidez, el de abajo velocidad media y como último los más lentos.

Es decir, de izquierda a derecha en el eje X aumentamos el tamaño de fichero, mientras que en el eje Y se aumenta la velocidad de transferencia. Podemos concluir también que el

número de clusters debería ser mayor, habiendo realizado nosotros la agrupación cualitativa.


2. Con el mismo número de iteraciones y agrupando los datos en 5 clases, ¿qué resultados se obtienen? ¿Cómo difieren de los anteriormente obtenidos?

Si realizamos el mismo agrupamiento de datos en 5 clases, se obtienen estos resultados:



Podemos observar que obtenemos el mismo resultado que el apartado anterior. El resultado de este solo difiere en el número de filas, o mejor dicho, clusters.


Aunque necesitemos más clusters, aumentar el número de estos no nos ayuda a solucionar el problema ya visto previamente. Nuestra herramienta de trabajo Weka, solo agrupa por filas, es decir, según velocidades, sin distinguir los tamaños de fichero. Debemos realizar nosotros la agrupación cualitativa otra vez:



Como conclusión, podemos decir que aumentar el número de clusters no ayuda a agrupar los datos de manera cualitativa ya que no se distinguen los diferentes tipos de ficheros: pequeños(primer columna),medianos(segunda columna) y grandes(tercera columna). Este agrupamiento debe ser realizado por nosotros ya que el Weka solo se encarga de realizar el agrupamiento cuantitativo. Es por ese motivo que el agrupamiento cualitativo es subjetivo e interpretativo, dependiendo de las características y rasgos de las instancias. El primer tipo de datos es numérico, mientras que el segundo se interpreta.

3. ¿Hay alguna característica especial en la carga proporcionada? Explícala con detalle.

Hay una característica especial en función del tamaño de los ficheros. Si representamos en el eje X el número de la instancia y en el eje Y el tamaño de fichero, podemos observar que a medida que aumenta el número de fichero, hay menos ficheros. Veamos que disminuyen los puntos a medida que se aumenta el valor del eje Y:



Si observamos detenidamente la función del tamaño de fichero, seguiría esta distribución:



Esta distribución es nombrada como **long-heavy-tail** y se caracteriza por tener un inicio exponencial decreciente (véase la zona verde) y otra facción donde va disminuyendo más

lentamente(zona amarilla). En nuestro caso, el eje X sería el tamaño del fichero y el eje Y la cantidad de ficheros. A medida que el tamaño crece encontramos menos ficheros, aunque más pesados. Sin embargo, encontramos muchísimos más ficheros pequeños en el principio del eje X.

En conclusión post-análisis, podemos decir que el Weka no tiene error alguno, sino que debemos realizar una agrupación cualitativa antes de la clusterización. Podemos concentrarnos en agrupar los ficheros por tamaño, es decir, por columnas. De esta manera obtendremos el resultado esperado.