

Práctica 7

Jaume Adrover Fernández
43235882E

Puntuación máxima: 1 punto

ENUNCIADO

Una empresa de almacenamiento en la nube monitoriza la actividad de sus usuarios, es decir, se guarda la hora de acceso del cliente, el tamaño del fichero al que se ha accedido y la cantidad de información transmitida por unidad de tiempo (hacer uso de los datos de la práctica 6). El director del departamento de informática de la empresa solicita calcular la cantidad de información transmitida por la red y el tamaño del fichero accedido para las 6 a.m. (recordar que la última hora monitorizada son las 5 a.m.).

- ¿Qué patrón siguen los datos monitorizados? Proporciona una representación gráfica.
- Calcula los valores solicitados para las 6 a.m. haciendo uso de la regresión lineal, medias móviles (usar los 4 últimos valores) y suavizado exponencial (peso fijo del 60%).
- ¿Qué técnica de predicción funciona mejor? ¿Por qué? ¿Cuál es la más adecuada para los datos con los que contamos?

SOLUCIÓN

1. ¿Qué patrón siguen los datos monitorizados? Proporciona una representación gráfica.

Para poder observar los datos monitorizados, primero realizamos las medias de tamaño de fichero y velocidad de transferencia según las horas. Esta funcionalidad se ha llevado a cabo mediante un script en R, véase la figura 23 en el contenido adicional(punto 4.1) . Aquí están los resultados, clasificados por hora:

Hora (24h format)	Tamaño fichero (MB)	Velocidad de transferencia (MB/s)
22	3442.89	905.1
23	3546.79	890.55

1	4447.97	904.23
2	4881.89	904.45
3	4949.22	903.64
4	4611.4	903.36
5	4775.23	904.11

Para poder observar mejor el patrón que siguen ambas variables, veamos su comportamiento de una manera mucho más gráfica:




Figura 1: gráfico de tamaño de fichero según la hora




Figura 2: gráfico de la velocidad de transferencia según la hora

Vistos ambos gráficos, podemos sacar la conclusión de que el tamaño sigue un patrón con tendencia ascendente, ya que a pesar de experimentar una bajada, los valores van superando el máximo anterior conseguido. Sin embargo, la velocidad de transferencia sufre pocas variaciones y por ese motivo podemos decir que sigue un patrón estacionario, donde el valor es regular y sufre pequeñas distorsiones, aunque se vuelve a equilibrar.

2. Calcula los valores solicitados para las 6 a.m. haciendo uso de la regresión lineal, medias móviles (usar los 4 últimos valores) y suavizado exponencial (peso fijo del 60%)

Antes de empezar, cabe destacar que la visualización de gráficos se ha hecho con un script de python, que se encuentra en el punto 4.2 de contenido adicional. Además, se han renombrado las clases de esta manera para que el eje de las X sea lineal y no pasar de 23 a 1 directamente, ya que son valores continuos. Veamos su renombramiento:

Hora	Número clase
22	1
23	2
1	3
2	4
3	5
4	6
5	7

De esta manera, para poder calcular la predicción de las 6 a.m, debemos sustituir la x por 8. De esta manera, todos los índices que correspondan a este valor, pertenecerán a las 6 a.m.

2.1 Regresión lineal

La regresión lineal es un método de predicción que se centra en la creación de una función que simulará el comportamiento de otra. Esta tiene un comportamiento lineal y sigue esta expresión:

$$y = a + bx$$

Donde **a** determina la intersección, el punto y donde se corta el eje en la coordenada x=0. Y **b** determina la pendiente de esta. Si b es menor que 0, esta función tiende a decrecer, mientras que en el caso contrario esta aumenta.

Veamos cómo se calculan ambos:

$$b = \frac{\sum_{i=1}^n x_i * y_i - n \cdot \bar{x} \cdot \bar{y}}{\sum_{i=1}^n x_i^2 - n \cdot \bar{x}^2}$$

$$a = \bar{y} - b \cdot \bar{x}$$

Conocidas las fórmulas de ambos parámetros, vamos a realizar los cálculos correspondientes:

• **Función de velocidad de transferencia según la hora:**

$$b_{speed} = \frac{\sum_{i=1}^n x_i * y_i - n \cdot \bar{x} \cdot \bar{y}}{\sum_{i=1}^n x_i^2 - n \cdot \bar{x}^2} = 899'05$$

$$a_{speed} = \bar{y} - b \cdot \bar{x} = 0'78$$

$$speed(x) = 899'05 + 0'78x$$

• **Función del tamaño de fichero según la hora:**

$$b_{size} = \frac{\sum_{i=1}^n x_i * y_i - n \cdot \bar{x} \cdot \bar{y}}{\sum_{i=1}^n x_i^2 - n \cdot \bar{x}^2} = 3432'12$$

$$a_{size} = \bar{y} - b \cdot \bar{x} = 236'77$$

$$size(x) = 3432'12 + 236'77x$$




Figura 3: regresión lineal sobre la velocidad




Figura 4: regresión lineal sobre el tamaño de ficheros

Para poder predecir el comportamiento, cogemos ambas funciones y sustituimos x por el nombre de clase de la hora correspondiente:

$$speed(8) = 905.29 \text{ MB/s}$$

$$size(8) = 5326.28 \text{ MB}$$

Podemos decir que la predicción para la velocidad de transferencia a las 6 es de 905.29 MB/s y un tamaño de fichero de 5326.28 MB.

2.2 Medias móviles

Las medias móviles intentan predecir de una manera muy simple el período siguiente a partir de la media de las observaciones anteriores. En nuestro caso, escogemos los 4 valores anteriores.

Veamos los procesos predichos para el tamaño y la velocidad:

$$size_8 = \frac{4881.89+4949.22+4611.4+4775.23}{4} = 4804.43 \text{ MB}$$

$$speed_8 = \frac{904.45+903.64+903.36+904.11}{4} = 903.89 \text{ MB/s}$$

De esta manera, se espera un tamaño de fichero de 4804.43 MB y una velocidad de transferencia de 903.89 MB/s a las 6 a.m.

2.3 Suavizado exponencial

El suavizado exponencial es similar a las medias móviles, aunque se coloca más peso en las observaciones recientes. Este pone más énfasis en estas muestras ya que predicen mejor el futuro cercano.

Veamos la fórmula correspondiente a la predicción:

$$f_{t+1} = f_t + \alpha(y_t - f_t)$$

2.3.1 Tamaño de fichero

Utilizando la fórmula ya vista anteriormente, obtenemos los siguientes resultados:

Hora	Velocidad de transferencia (MB/s)	Predicción velocidad de transferencia(MB/s)
22	905.1	905.1

23	890.55	896.37
1	904.23	901.086
2	904.45	903.1044
3	903.64	903.42
4	903.36	903.3863
5	904.11	903.8205

Cabe aclarar que la predicción de la hora siguiente está ubicada en la misma fila que la hora anterior. Por ejemplo: la predicción de las 6 está en la misma fila que las 5.

Viendo estos resultados, decimos que esperamos un tamaño de fichero de unos 903.8 MB a las 6 a.m.

2.3.2 Velocidad de transferencia

El resultado de aplicar la fórmula del suavizado exponencial se refleja en la siguiente tabla:

Hora	Tamaño de fichero(MB)	Predicción tamaño de fichero(MB/s)
22	3442.89	3442.89
23	3546.79	3505.23
1	4447.97	4070.874
2	4881.89	4557.48
3	4949.22	4792.53
4	4611.4	4683.8502
5	4775.23	4738.68

En conclusión, esperamos una velocidad de transferencia de unos 4738.7 MB/s a las 6 a.m.

3.¿Qué técnica de predicción funciona mejor? ¿Por qué? ¿Cuál es la más adecuada para los datos con los que contamos?

Para poder observar qué técnica es la que funciona mejor vamos a realizar una predicción sobre una hora de la cual ya sepamos el valor real y compararemos qué metodología tiene una menor diferencia. En nuestro caso, hemos elegido las 4 a.m ya que para realizar las medias móviles necesitamos 4 valores anteriores, solo pudiendo empezar a predecir a partir de las 3.am. Cabe destacar que la diferencia está en valor absoluto ya que no diferenciamos si se ha pasado del valor o le falta por llegar, sino que solo tenemos en cuenta la distancia.

3.1.1 Regresión lineal

En primer lugar, vamos a realizar la predicción mediante una regresión lineal. Vamos a utilizar el valor 6 para la x, teniendo en cuenta el renombramiento de clases.

$$size(6) = 4852.74 MB$$

$$speed(6) = 903.73 MB/s$$

	Valor real	Predicción	Diferencia (valor absoluto)
Tamaño fichero (MB)	4611.4	4852.74	241.34
Velocidad de transferencia (MB/s)	903.36	903.73	0.37

3.1.2 Medias móviles

En cuanto a las medias móviles, realizamos la media aritmética de los últimos 4 valores y obtenemos las siguientes predicciones:

	Valor real	Predicción	Diferencia (valor absoluto)
Tamaño fichero (MB)	4611.4	4456.4675	154.93
Velocidad de transferencia (MB/s)	903.36	900.71	2.65

3.1.3 Suavizado exponencial

Y en último lugar,

	Valor real	Predicción	Diferencia (valor absoluto)
Tamaño fichero (MB)	4611.4	4792.53	181.13
Velocidad de transferencia (MB/s)	903.36	903.42	0.06

3.2 Técnica más adecuada

Para poder saber qué técnica es la más adecuada, vamos a comprobar cual tiene una menor diferencia en cuanto a las predicciones ya calculadas anteriormente.

En primer lugar, observamos que la técnica más precisa para el tamaño de fichero es las medias móviles, con una imprecisión de 154.93 MB, menor que la regresión lineal (241.34 MB) o la del suavizado exponencial (181.13 MB). Por otro lado, podemos ver que el suavizado exponencial funciona casi a la perfección con la velocidad de transferencia, concibiendo así solo un error de 0.06 MB/s, superando con creces a la regresión lineal y a las medias móviles.

En conclusión, podemos afirmar que escogemos las medias móviles para el tamaño de fichero y el suavizado exponencial para las velocidades. Esta decisión es fruto de seleccionar los métodos con menor error.

4.Contenido adicional

4.1 Script R

```
library(tidyverse)

df22=read.csv('cleanData2.csv')
df23=read.csv('cleanData2.csv')
df1=read.csv('cleanData2.csv')
df2=read.csv('cleanData2.csv')
df3=read.csv('cleanData2.csv')
df4=read.csv('cleanData2.csv')
df5=read.csv('cleanData2.csv')

#HORA 22
df22<-df22[which(df22$hour==22),]
mean(df22$size)
mean(df22$speed)

#HORA 23
df23<-df23[which(df23$hour==23),]
mean(df23$size)
mean(df23$speed)

#HORA 1
df1<-df1[which(df1$hour==1),]
mean(df1$size)
mean(df2$speed)

#HORA 2
df2<-df2[which(df2$hour==2),]
mean(df2$size)
mean(df2$speed)
```

```

#HORA 3
df3<-df3[which(df3$hour==3),]
mean(df3$size)
mean(df3$speed)

#HORA 4
df4<-df4[which(df4$hour==4),]
mean(df4$size)
mean(df4$speed)

#HORA 5
df5<-df5[which(df5$hour==5),]
mean(df5$size)
mean(df5$speed)

```

Figura 23: script en R para determinar las medias según horas

4.2 Script python

```

import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
import numpy as np
from scipy.stats import linregress
x=[[22],[23],[1],[2],[3],[4],[5]]
y=[[3442.89],[3545.79],[4447.97],[4881.89],[4949.22],[4611.4],[4775.23]]
#TAMAÑO FICHERO
#y=[[905.1],[890.55],[904.23],[904.45],[903.64],[903.36],[904.11]]
#VELOCIDAD TRANSFERENCIA

x1=np.arange(7)
x11=[[0],[1],[2],[3],[4],[5],[6]]
xB=[1,2,3,4,5,6,7 ]
#yB=[3442.89,3545.79,4447.97,4881.89,4949.22,4611.4,4775.23] #TAMAÑO FICHERO
yB=[905.1,890.55,904.23,904.45,903.64,903.36,904.11] #VELOCIDAD

#Regresión lineal
rg=LinearRegression()
rg.fit(x11,y)#entrenamos la regresión lineal
y2=rg.predict(x11)#predecimos

```

```
plt.scatter(x1,y,color='green')
#plt.ylim(850,1000)
plt.plot(x1,y2,color="blue")
plt.xticks(ticks=x1,labels=x)
plt.xlabel("Hora")
plt.ylabel("Tamaño de fichero (MB)")
plt.title("Gráfico de tamaño fichero según hora")
plt.show()
```

Figura 24: script python para visualizar los gráficos correspondientes

De este script cabe decir que las partes comentadas se van alternando, para ilustrar o el tamaño o la velocidad.